协同分配

- 1. 计算任务: M个相同计算任务(M>N), 组成队列
- 2. 算力资源: cpu核数
- 3. 系统结构: 1 服务器——N个客户端: 每个客户端对应一个容器, 有不同大小的算力资源配置
- 4. 两层算法:
 - 1. 预分配算法:根据容器设备和任务配置情况,给出最合适当前任务分发的设备
 - 2. 动态分配算法:根据设备资源使用情况,动态调整容器资源配置
- 5. 系统设计
 - 1.1服务器 (**server.py**) ——N个计算节点 (N可配置)
 - 2. 计算任务(cnn.py): cifar10 CNN图像识别,可配置其运行时间,从而控制任务规模
 - 3. 节点资源可用算力v: 当前节点可用算力每隔T时间根据正态分布N(m,A)在[cpu-1, cpu+1]中变化 (m,A,T可配置)

4. 算法设置:

- 1. 静态调度Static Assign(**task_schedule.py**): 系统将计算任务平均分给N个计算节点,在每个计算节点预分配固定算力用于执行任务,计算节点执行完毕后返回。
 - 1. base_assign:将任务按照顺序平均分配给各个节点
 - 2. random_assign:将任务随机分配给各个节点
 - 3. **min_min**: 将当前任务优先分配给之前任务执行总时间最少(最早完成之前任务) 的节点
- 2. 动态调度: 系统将计算任务平均分给N个计算节点,每个计算节点根据当前可用算力动态调整使用算力(考虑算力调动态分配的过程损耗),计算节点执行完毕后返回。
 - 1. **cpu_change**:模拟cpu资源变化的情况,并当没有动态调度时,只能减少cpu数量,无法扩张
 - 2. **cpu_change_ca**:模拟cpu资源变化的情况,并当没有动态调度时能够根据给定大小伸缩容器cpu数量
- 3. 协同分配:系统根据当前算网状态,依次将任务按最优适配分配给对应计算节点,每个计算节点根据当前可用算力动态调整使用算力(考虑算力调动态分配的过程损耗),计算节点执行完毕后返回。
- 5. 性能分析——评价指标
 - 1. 任务完成数: 一定时间段内执行计算任务的总数量
 - 2. 算网资源利用率:指全网可用算力资源的使用效率
 - 3. 应用执行延迟(效率):指M个计算任务的完成延迟平均?

待解决

- 1. 当各节点在不同设备上时, docker daemon控制容器配置
- 2. 动态分配算法研究
- 3. 性能分析实现
- 4. gpu算力动态分配及k8s合理性